



基于字符相似性与机器学习的互联网垃圾文本检测系统

规则、字符变体、TF-IDF 与 RoBERTa 融合检测实践

sb

中山大学

2026 年 6 月



内容提要

背景与目标

数据与检测方法

实验结果与分析

系统展示与总结



研究背景与检测难点

垃圾文本正在主动“伪装”

形近字替换

“加微信”写成“加薇信”，绕过精确关键词匹配。

缩写与混写

使用 vx、wx、数字和外语片段隐藏联系方式。

分隔符插入

“领·取”“私聊”“扫码”等写法破坏连续文本特征。

典型变体文本

加薇信领·取优惠

单一关键词规则难以兼顾召回率与误报率；单一统计模型也难以覆盖持续变化的对抗写法。

核心挑战

识别语义意图，而不只匹配表面字符



项目目标与总体方案

构建一个面向真实互联网文本的多语言垃圾检测系统

多语言分类


结合传统机器学习与多语言 RoBERTa，对中文、英文等文本完成正常 / 垃圾二分类。

风险量化

将规则、字符变体与模型概率统一为 0-1 风险分数，支持阈值调整。

可解释输出

返回命中关键词、链接、联系方式、变体写法及各模块分数。





数据集与处理流程

传统模型数据


2,400

小规模标注文本，用于训练 TF-IDF/LR 基线并快速验证完整流程。

RoBERTa 数据 百万条级别

汇总多个公开垃圾文本数据源，覆盖中文、英文等多种语言。

统一数据处理管线



统一标签： ham = 0, spam = 1；训练前完成随机化与去重。



规则与字符变体检测

可解释规则层

链接

http、www、可疑域名

利益诱导

返现、红包、优惠、佣金

联系方式

手机号、微信、vx / wx

高风险词

刷单、博彩、贷款、套现

字符变体归一化

薇 / 微 / v

微

辛 / 芯 / 心

信

wx / vx / v 信

微信

处理效果

加 薇 信 领·取 优 惠

→ 加微信领取优惠



TF-IDF/LR: 传统机器学习基线

轻量、快速、可复现



通过字符级 n-gram 捕捉“加微信”“返现”“扫码”等局部组合，无需中文分词，训练与推理成本低。

1-4

字符 n-gram 范围

Balanced

类别权重设置

Baseline

传统方法定位



百万级多语言 RoBERTa

百万级

去重后的多源训练数据

多语言

中文、英文等文本

4 × H100

并行训练设备

≈ 2 小时

完整训练耗时

项目的主要语义模型

上下文建模


基于 XLM-RoBERTa 编码整段文本语义，减少仅凭单个关键词造成的误判。

跨语言泛化

统一模型处理多语言输入，为英文短信和混合语言广告提供检测能力；训练过程以 F1 选择最佳模型。



多模块融合架构




$$\text{score} = 0.20 \cdot \text{rule} + 0.70 \cdot \text{model} + 0.10 \cdot \text{variant}$$

模型模式可在 TF-IDF/LR、RoBERTa、双模型与纯规则之间切换



实验设置与评价指标

实验流程



四项核心指标

Accuracy

整体分类正确率

Precision

垃圾判定的准确程度

Recall

实际垃圾文本检出率


F1

Precision 与 Recall 的平衡

垃圾检测更关注 Precision 与 Recall 的平衡，因此训练过程以 F1 选择最佳模型。



不同检测方法结果对比



规则模型

可解释性强，能够快速定位链接、联系方式和高风险词。

传统基线

字符级 TF-IDF/LR 在当前评测集上提供稳定、低成本的分​​类能力。

融合检测

结合规则、变体与模型概率，兼顾结果性能和可解释性。



多语言与变体案例分析

中文变体广告

加 薇 信 免费领·取资料

识别：形近字 + 分隔符 + 引流意图

英文垃圾短信

Claim your free prize now!

识别：RoBERTa 跨语言语义分类

正常技术文本

微信小程序开发需要配置环境

判定：结合上下文，降低关键词误报

混合语言广告

Add vx for 优惠 and bonus

识别：缩写规则 + 多语言模型

规则负责“看见风险信号”，RoBERTa 负责“理解上下文意图”。



系统演示与项目总结

▶ DEMO

播放系统录屏

已完成的系统能力

检测模式 TF-IDF/LR、RoBERTa、双模型、规则变体

交互功能 单条检测、批量上传、结果下载、模块对比

解释输出 风险分数、关键词高亮、归一化与命中原因

数据与标注

规则与基线

RoBERTa 训练

系统与展示



系统演示与项目总结

感谢聆听

Q & A

基于字符相似性与机器学习的互联网垃圾文本检测系统